

Proje Raporu: Matris Ayrıştırma ile Öneri Sistemi

Geliştirici: Serkan Polat | Yöntem: L2-Düzenleştirilmiş Gradyan İnişi (L2-Regularized GD)

1. PROBLEM TANIMI VE AMAÇ

Bu çalışmada, 20 kullanıcı ve 1000 filminden oluşan, son derece yüksek seyreklik oranına (%99 boşluk) sahip bir derecelendirme matrisindeki eksik verilerin tamamlanması amaçlanmıştır. Veri setinde toplam 20.000 olası hücre bulunmasına rağmen, yalnızca 200 adet gözlemlenen (observed) rating değeri yer almaktadır. Temel amaç, bu kısıtlı gözlem verisi üzerinde latent factor (gizli etmen) modelini eğiterek, kullanıcıların henüz izlemediği ve puanlamadığı filmlere yönelik baseline modele göre daha iyi genelleme yapan makul tahminler üretmektir.

2. MATEMATİKSEL MODEL VE LOSS FONKSİYONU

Problemın çözümünde Low-Rank Matrix Factorization yaklaşımı benimsenmiştir. Hedef matris, $k = 4$ gizli etmen boyutu üzerinden, kullanıcı özelliklerini temsil eden u (20×4) matrisi ve film özelliklerini temsil eden v (4×1000) matrisine ayrıştırılmıştır.

Algoritmik kararlılığı artırmak adına, eğitim öncesinde eğitim kümesindeki gözlemlenen rating değerlerinin ortalaması ($\mu = 3.1062$) hesaplanmış ve hedef matris merkezleştirilmiştir ($r_{\text{centered}} = r - \mu$). Model tahmini şu şekilde ifade edilir:

$$R_{\text{tahmin}} = \mu + u \cdot v$$

Eğitim sırasında optimize edilen L2 düzenleştirilmiş kayıp (loss) fonksiyonu, koddaki gradyan adımları ve türevler ile tam uyum sağlayacak şekilde (λ / N) katsayısı kullanılarak şu standartta tanımlanmıştır:

$$J(u, v) = (1 / N) \cdot \sum [(u_i \cdot v_j - r_{ij_merkez})^2] + (\lambda / N) \cdot [\|u\|^2 + \|v\|^2]$$

Burada Σ sembolü gözlemlenen tüm (i, j) kullanıcı-film çiftleri üzerinden toplamı, N eğitim kümesindeki veri sayısını (160 adet) ve λ ise aşırı öğrenmeyi (overfitting) sınırlayan düzenleştirme katsayısını ifade eder. Bu formülasyon, koddaki gradyan güncellemelerinin matematiksel zeminini doğrudan yansıtmaktadır.

Kritik Teorik Not: Bu kayıp fonksiyonu, u ve v parametrelerinin çarpımını içerdiği için eşzamanlı olarak **jointly convex (birlikte dışbükey) değildir**. Problem biconvex bir yapıya sahip olup, Gradyan İnişi algoritması ile yerel bir optimum çözüme (local minimum) başarıyla yakınsatılmıştır.

3. ÇÖZÜM YAKLAŞIMI VE DOĞRULAMA (METRİK ANALİZİ)

Vektörize edilmiş Batch Gradient Descent algoritması 5000 epoch boyunca koşturulmuştur. Modelin ezberleyip ezberlemediğini (overfitting) objektif bir şekilde değerlendirmek amacıyla, eldeki 200 rating değeri %80 eğitim

(160 adet) ve %20 doğrulama (40 adet) olarak ikiye bölünmüştür. Hocanın isterleri doğrultusunda sabit tutulan $k = 4$ gizli etmen boyutu için farklı λ değerlerinin ürettiği tutarlı deneysel sonuçlar aşağıda detaylandırılmıştır:

Metrik / Düzenleştirme (λ)	En İyi Epoch	Eğitim (Train) RMSE	Doğrulama (Validation) RMSE	Matematiksel ve Algoritmik Analiz
$\lambda = 0.10$	4000	0.1889	1.3791	Düşük regülasyon nedeniyle model eğitim verisine yüksek uyum sağlamış (0.1889 RMSE) ancak doğrulama setinde overfitting eğilimi göstermiştir. Başlangıç loss değeri (Epoch 0) teorik beklentiye uygun olarak ~ 11.07 seviyesindedir.
$\lambda = 0.50$	4100	0.3205	1.3866	Düzenleştirme etkisi artırılarak matris ağırlıklarının büyümesi kısıtlanmış, eğitim hatası kabul edilebilir bir düzeyde tutulurken model kararlılığı korunmuştur.
$\lambda = 1.00$	4999	0.4407	1.3942	Gradyan adımlarının sönümlenmeden kararlı şekilde yakınsadığını gösterir. Eğitim verisindeki ~ 0.44 'lük RMSE sapması, L2 cezasının ağırlıkları başarıyla baskıladığının kanıtıdır.

Baseline Karşılaştırması: Hiçbir öğrenme gerçekleştirmeden doğrudan global ortalamayı (μ) tahmin olarak kabul eden Baseline modelinin doğrulama RMSE skoru **1.4187**'dir. Geliştirilen matris ayrıştırma modeli, kısıtlı veriye ve yüksek latent boyutuna rağmen düzenleştirme sayesinde baseline modelden daha başarılı bir genelleme performansına ulaşmıştır.

4. SONUÇ VE DEĞERLENDİRME

Elde edilen sonuçlar, modelin eldeki son derece kısıtlı eğitim verisinden belirli ölçüde anlamlı gizli etmenler öğrenebildiğini göstermektedir. Veri kümesinin aşırı küçük olmasından (yalnızca 160 eğitim noktası) kaynaklanan yüksek aşırı öğrenme (overfitting) riski, L2 düzenlemesi ile belirli ölçüde azaltılmış ve yumuşatılmıştır. Matris boyut sınırları (20 x 1000) eksiksiz korunmuş olup, çözüme yönelik adımlar teorik sınırlarla ve pratik kod çıktılarıyla akademik bir tutarlılık içerisinde çalışmaktadır.